

UNIVARIATE LINEAR REGRESSION

Prof. Nielsen Rechia

nielsen.machado@uniritter.edu.br

Univariate Linear Regression

2

Paradigmas	Supervisionado		Não-supervisionado	
	Classificação	Regressão	Análise associativa	Agrupamento (clustering)
Tarefas	Outros		Redução de dimensionalidade	Outros

7 tarefas comuns de aprendizado de máquina:
<http://vitalflux.com/7-common-machine-learning-tasks-related-methods/>

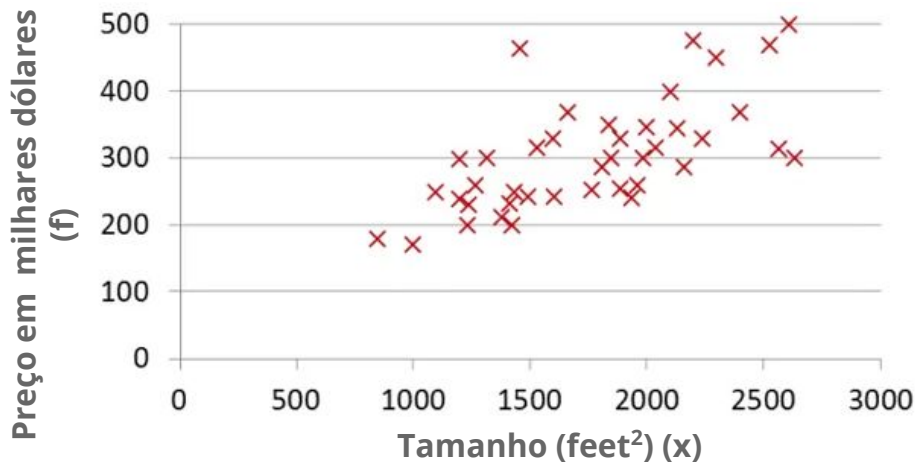
Regressão Linear

O objetivo da regressão é aproximar um valor para um objeto ainda não conhecido, com base em objetos conhecidos.

A Regressão Linear é diferente da classificação, onde o objetivo é aproximar uma categoria ao objeto.

Regressão Linear

De acordo com o tamanho e o preço de casas, qual o preço de uma nova casa a venda dado o seu tamanho?

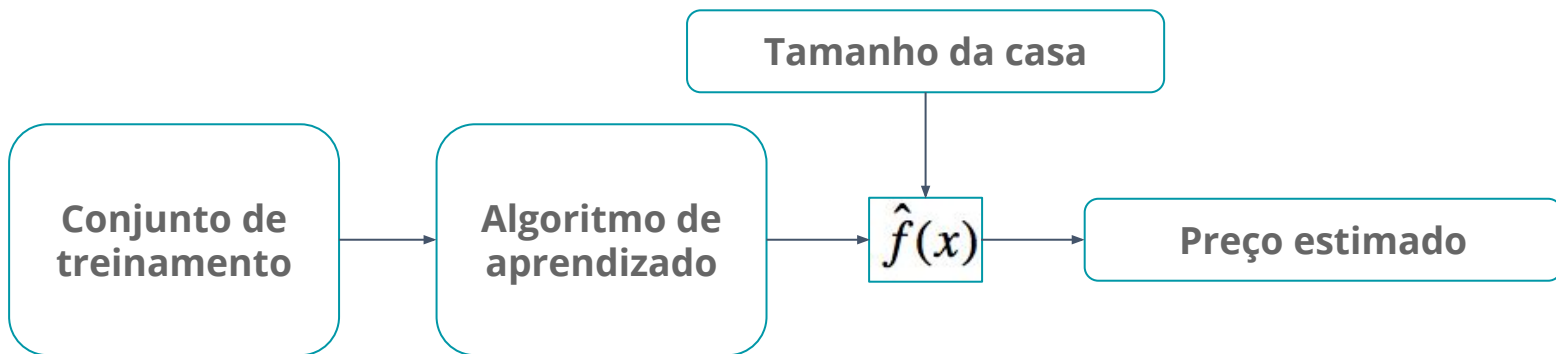


Regressão Linear

5

Utilizamos regressão linear (univariada = apenas um atributo), onde o modelo é dada por:

$$\hat{f}(x) = \theta_0 + \theta_1 x$$



Exercícios

Fazer uma projeção para cada um dos parâmetros (i.e. pesos) a seguir para cada um dos valores de x :

$$\hat{f}(x) = \theta_0 + \theta_1 x$$

$$\theta_0 = 1.5$$


$$\theta_1 = 0$$

$$\theta_0 = 0$$

$$\theta_1 = 0.5$$

$$\theta_0 = 1$$


$$\theta_1 = 0.5$$



Exercícios


7

Quais os valores de Θ_0 e Θ_1 ?



Regressão Linear

A Idéia é definir os valores de Θ_0 e Θ_1 visando minimizar a função de custo do aprendizado.



Regressão Linear

Temos um modelo: $\hat{f}(x) = \theta_0 + \theta_1 x$

Alguns parâmetros: Θ_0 e Θ_1


Uma função de custo: $J(\theta_0, \theta_1) = \frac{1}{2N} \sum_{i=1}^N \left(\hat{f}(x^{(i)}) - f(x^{(i)}) \right)^2$

Um objetivo: $\min_{\theta_0, \theta_1} J(\theta_0, \theta_1)$

Exercícios

10


Dado o seguinte conjunto de dados e os parâmetros, calcule o custo das predições:



$$\begin{aligned}\Theta_0 &= 0, \Theta_1 = 0 \\ \Theta_0 &= 0, \Theta_1 = 0.5 \\ \Theta_0 &= 0, \Theta_1 = 1\end{aligned}$$

$$\begin{aligned}\Theta_0 &= 0, \Theta_1 = 1.5 \\ \Theta_0 &= 0, \Theta_1 = 2 \\ \Theta_0 &= 0, \Theta_1 = 2.5\end{aligned}$$


Preencha o gráficos a seguir:



Regressão Linear

11


A função de custo para um parâmetro é convexa



Regressão Linear

12



A função de custo também é convexa para dois parâmetros



Regressão Linear

13

Exemplo



Regressão Linear

Para iniciar devemos escolher arbitrariamente os valores dos parâmetros

Para minimizar a função de custo devemos atualizar os pesos dos parâmetros

Os valores devem ser alterados continuamente até um determinado critério de parada (convergência)

Regressão Linear

15

O antigo valor do j-ésimo parâmetro, menos

vezes a taxa de aprendizado

$$\theta_j := \theta_j - \alpha \frac{\partial}{\partial \theta_j} J(\theta_0, \theta_1)$$

O j-ésimo parâmetro recebe


A derivada da função de custo em relação ao j-ésimo parâmetro

Regressão Linear

16

Entendendo a derivada

A derivada parcial indica como a função de custo se altera quando um parâmetro tem seu valor modificado



com apenas um parâmetro, $\theta \in J(\theta)$

$$\theta := \theta - \alpha \frac{d}{d\theta} J(\theta)$$

$$\theta := \theta - \alpha \text{ (num positivo)}$$

$$\theta := \theta - \alpha \text{ (num negativo)}$$

Regressão Linear

17

A derivada parcial nos mostra apenas a direção em que o parâmetro deve ser modificado.

Não nos mostra o tamanho correto do passo que deve ser obtido com a taxa de aprendizado



Regressão Linear

18

Se a taxa de aprendizado for muito alta, podemos passar “por cima” do ótimo global

Se a taxa de aprendizado for muito baixa, podemos demorar muito para convergir

No free launch!



Regressão Linear

Então, para fazer a atualização de pesos, utilizamos o gradiente descendente

Gradiente é como chamamos o grupo de derivadas de diversos parâmetros

Utilizamos uma taxa de aprendizado para ditar o passo em torno de melhores resultados

Regressão Linear

20

A atualização dos pesos deve ser simultânea!

Não atualize o valor do parâmetro $j + 1$, com base no valor atualizado do parâmetro j

Em vez disso, calcule antes todos os novos valores de parâmetros, e só então faça as atribuições

$$\text{temp0} := \theta_0 - \alpha \frac{\partial}{\partial \theta_0} J(\theta_0, \theta_1)$$

$$\text{temp1} := \theta_1 - \alpha \frac{\partial}{\partial \theta_1} J(\theta_0, \theta_1)$$

$$\theta_0 := \text{temp0}$$

$$\theta_1 := \text{temp1}$$

Implementação correta

Regressão Linear

Para a função de custo da regressão linear, a atualização de pesos (com derivadas calculadas) é:

$$\theta_0 := \theta_0 - \alpha \frac{1}{N} \sum_{i=1}^N (h_{\theta}(x^{(i)}) - y^{(i)})$$

$$\theta_1 := \theta_1 - \alpha \frac{1}{N} \sum_{i=1}^N (h_{\theta}(x^{(i)}) - y^{(i)}) \cdot x^{(i)}$$


Regressão Linear

22

Gradiente Descendente


$$h_{\theta}(x)$$

(for fixed θ_0, θ_1 , this is a function of x)



$$J(\theta_0, \theta_1)$$

(function of the parameters θ_0, θ_1)




Regressão Linear

23

Gradiente Descendente


$$h_{\theta}(x)$$

(for fixed θ_0, θ_1 , this is a function of x)



$$J(\theta_0, \theta_1)$$

(function of the parameters θ_0, θ_1)




Regressão Linear

24

Gradiente Descendente


$$h_{\theta}(x)$$

(for fixed θ_0, θ_1 , this is a function of x)



$$J(\theta_0, \theta_1)$$

(function of the parameters θ_0, θ_1)




Regressão Linear

25

Gradiente Descendente


$$h_{\theta}(x)$$

(for fixed θ_0, θ_1 , this is a function of x)



$$J(\theta_0, \theta_1)$$

(function of the parameters θ_0, θ_1)




Regressão Linear

Gradiente Descendente


$$h_{\theta}(x)$$

(for fixed θ_0, θ_1 , this is a function of x)



$$J(\theta_0, \theta_1)$$

(function of the parameters θ_0, θ_1)




Regressão Linear

27

Gradiente Descendente


$$h_{\theta}(x)$$

(for fixed θ_0, θ_1 , this is a function of x)



$$J(\theta_0, \theta_1)$$

(function of the parameters θ_0, θ_1)




Regressão Linear

28

Gradiente Descendente


$$h_{\theta}(x)$$

(for fixed θ_0, θ_1 , this is a function of x)



$$J(\theta_0, \theta_1)$$

(function of the parameters θ_0, θ_1)




Regressão Linear

29

Gradiente Descendente


$$h_{\theta}(x)$$

(for fixed θ_0, θ_1 , this is a function of x)



$$J(\theta_0, \theta_1)$$

(function of the parameters θ_0, θ_1)




Regressão Linear

30

Gradiente Descendente


$$h_{\theta}(x)$$

(for fixed θ_0, θ_1 , this is a function of x)



$$J(\theta_0, \theta_1)$$

(function of the parameters θ_0, θ_1)



Exercícios

Dados os seguintes parâmetros, realize a atualização de pesos:


$$\alpha = 0.5$$

$$\Theta_0 = 0.1$$

$$\Theta_1 = 1$$

$$X = [0, 1, 2]$$


$$f_x = [0, 1, 4]$$



Regressão Linear

32

A função de custo é sempre convexa em um problema de regressão linear



Regressão Linear

33

Para realizar a atualização dos pesos dos parâmetros é necessário passar um batch (lote) pelo modelo

Esse batch pode ser de uma instância ou de todo conjunto de treino

Para otimizar, normalmente utilizamos quantidades multiplas de 8

O processo de passagem do batch pode ser estocástico (variáveis aleatórias)

O Gradiente Descendente pode convergir mesmo que a taxa de aprendizado seja fixa.

Para isso a taxa de aprendizado não pode ser muito elevada

Além disso, a taxa de aprendizado pode ser decrementada ao longo do treinamento

Regressão Linear

34

Passada de um batch: iteração

Passada do conjunto de treino: época



Exercício prático

35

Implementar uma regressão linear para prever qual o lucro, tendo como base o tamanho da população de um determinado local, com o dataset Regressão Univariada -> ex1data1.csv"

Defina uma % do conjunto de dados para treino e teste (sugestão 50% 50%)

Inicie os parâmetros Θ_0 e Θ_1 de forma randômica

Defina a taxa de aprendizado inicial

Atualize os pesos

Realize o processo até atingir convergência (diferença no custo de uma iteração para a outra não é significativa)

Conclusão

36

Leitura recomendada:

Apêndice D de Introduction to Data Mining

